项目研究报告

项目名称

“慧眼除垢，化繁为简”

——基于ACT端到端大模型的自适应擦拭系统及工业应用

队伍编号：CRAIC202664UA8QH3

团队编号：CRAIC2026-TEAM-XM48FSBW

团队名称：智仪维创队



摘要

工业生产现场正在从人工巡检、定期维护向智能运维、在线感知和无人化辅助作业演进，但传统指针式仪表、数字面板和控制柜窗口仍大量存在。粉尘、油污、水汽和反光会降低仪表可见性，进而影响人工读数和机器视觉识别的可靠性。仪表表面维护不仅是清洁动作，更是工业视觉巡检链路中的前端保障环节。

本项目以“慧眼除垢，化繁为简”为总体思路，受到人形机器人舞台化展示和工业具身智能发展的启发，将研究对象聚焦到工业仪表擦拭这一具体任务。我们具体实现的任务如下：

其一，团队完成了本地示教、AutoDL 云端训练和本地部署验证的工程闭环；其二，围绕标准擦拭、位置偏移、尺寸变化、污渍判断、海绵抓取偏差、光照扰动、真实厂房采集和失败样本补录等场景整理了 201 个 episode；其三，采用 ACT 动作分块策略学习从全局图像、腕部图像、关节状态和夹爪状态到连续动作块的映射，使机械臂完成海绵抓取、仪表定位、污渍判断、擦拭执行和复位。

实验与统计分析表明，多视角输入、关节状态融合和失败样本微调能够改善仪表位置变化、污渍状态差异和海绵抓取偏差下的任务表现。报告围绕数据集构成、训练损失收敛、模型消融、污渍判断、末端定位偏差、阶段耗时和失败类型等结果展开分析，并进一步讨论系统在固定点位巡检、仪表读数前端维护和非结构化清洁任务中的应用价值。

关键词：工业仪表维护；ACT；LeRobot；AutoDL 云端训练；端到端控制；模仿学习；机械臂擦拭；具身智能

目录

摘要 I
目录 II
第一章 绪论 1
第二章 项目背景与国内外研究现状 3
2.1 工业仪表污染与巡检风险 3
2.2 国内外研究现状 4
第三章 项目研究内容与技术路线 6
3.1 系统硬件与 LeRobot 运行环境 6
3.2 多工况示教数据采集 7
3.3 ACT 端到端动作学习方法 10
第四章 模型训练、实机测试与结果分析 14
4.1 消融测试与微调效果 14
4.2 失败类型、污渍判断与定位偏差 16
4.3 阶段耗时与综合指标 19
第五章 项目创新点、应用前景与社会价值 21
5.1 创新点分析 21
5.2 应用前景与社会价值 22
第六章 存在问题与后续改进方向 24
6.1 当前存在的问题 24
6.2 后续改进方向 24
6.3 项目总结 26
参考文献 27

第一章 绪论

工业现场的智能化升级并不只体现在新增高端设备和复杂控制系统上，也体现在对既有设备、传统仪表和基础维护流程的再组织、再感知和再自动化。当前，许多工厂正在建设数字化巡检、机器视觉读数和智能运维平台，但传统指针式仪表、数字显示面板和控制柜窗口仍广泛存在于实际生产系统中。这些设备往往安装周期长、数量多、分布分散，是工业现场运行状态的直接信息入口。对于此类仪表而言，表面可见性直接影响人工读数、相机采集和后续状态判断的可靠性。

在实际运维过程中，仪表表面污染是一类容易被忽视但频繁出现的问题。粉尘、油污、水汽、反光和人工接触痕迹会降低仪表读数清晰度，使巡检人员需要先擦拭再读取，也会使机器视觉系统面临图像模糊、局部遮挡和识别置信度下降等问题。与大型维修、复杂装配或高风险作业相比，仪表擦拭任务的单次操作并不复杂，但它具有重复性强、点位数量多、环境差异明显、工具接触状态不稳定等特点。正因如此，该任务适合作为具身智能技术进入工业维护场景的一个具体切入点：任务边界清晰，实验条件可控，同时具有真实的工业应用背景。

本项目的灵感来源于近年人形机器人舞台化展示与工业具身智能的发展。2026 年中央广播电视总台春节联欢晚会中，人形机器人在武术、舞蹈和人机协同表演中体现出较好的动作同步性和运动控制能力，其背后反映的是示教数据、动作组织、感知反馈和控制执行之间的系统协同。该现象启发我们思考：如果较复杂的舞台动作能够通过数据、模型和控制系统被机器人较稳定地复现，那么工业现场中大量重复、低风险但频繁发生的维护动作，也可以尝试通过示教数据和端到端策略学习来完成。与舞台展示相比，工业维护动作更强调稳定性、可复现性和场景约束，因此也更适合作为具身智能从演示走向应用的过渡型任务。

基于上述认识，本项目将研究对象聚焦为工业仪表擦拭任务，提出“慧眼除垢，化繁为简”的总体思路。其中，“慧眼”强调双相机视觉感知和污渍状态判断，“除垢”对应仪表表面维护任务，“化繁为简”则体现项目试图减少传统轨迹规划、显式建模和复杂条件规则的依赖，通过示教数据和 ACT 动作分块模型学习从视觉观测到机械臂动作序列的映射关系。项目并不追求覆盖所有工业清洁场景，而是在固定或半固定巡检点位中验证机械臂完成仪表表面维护的可行性。

项目整体实物结构和擦拭执行过程由团队在实验平台中拍摄整理，如图 1-1 和图 1-2 所示。

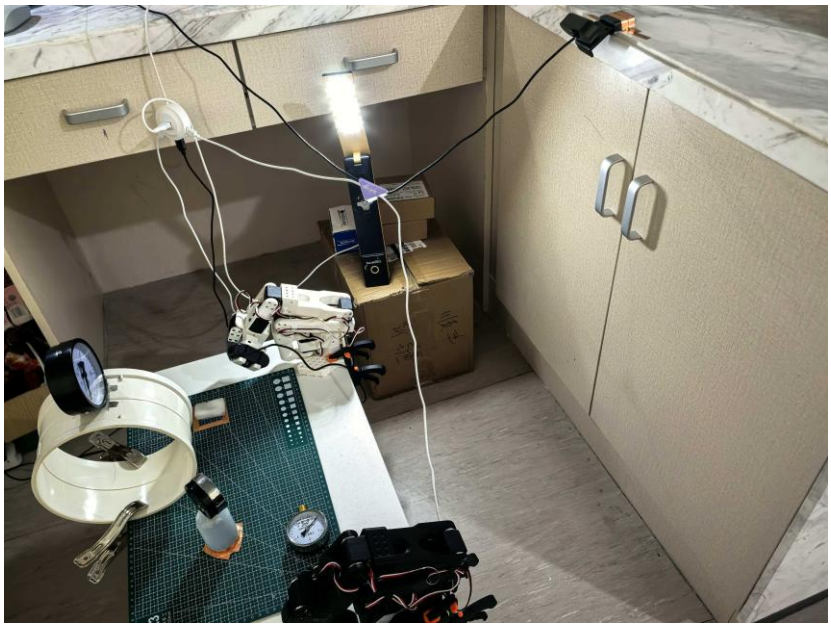


图 1-1 项目整体系统实物图

从图 1-1 可以看出，项目平台由桌面工作区、机械臂、相机、仪表对象和擦拭工具共同组成。该图说明系统具有完整的物理执行环境，后续算法训练和数据采集均围绕这一真实平台展开。

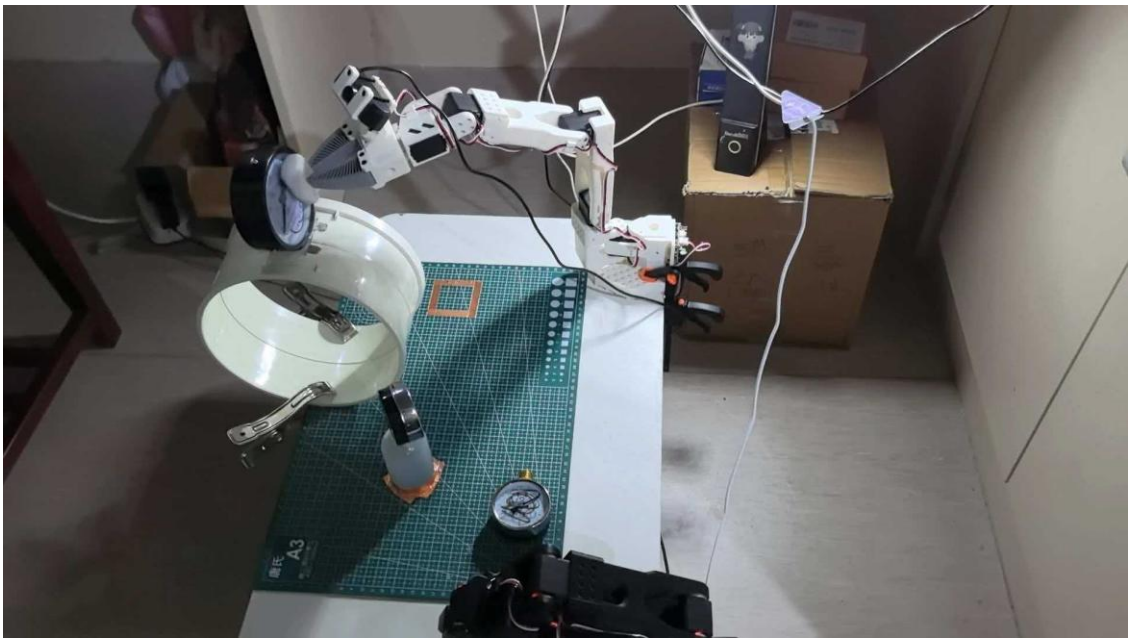


图 1-2 机械臂擦拭仪表过程图

图 1-2 呈现了机械臂夹持海绵接近仪表并执行擦拭的状态。该图反映出任务不仅包含末端移动，还涉及工具抓取、目标接近、接触擦拭和安全复位等连续动作环节。

第二章 项目背景与国内外研究现状

2.1 工业仪表污染与巡检风险

图 2-1 根据工业仪表维护场景中的问题链路，结合团队对工厂仪表污染现象的观察，使用 PowerPoint 绘制了从“污染形成”到“读数风险”再到“自动化维护需求”的逻辑关系，把项目问题从单次擦拭动作提升到巡检可靠性和智能运维前端保障层面。

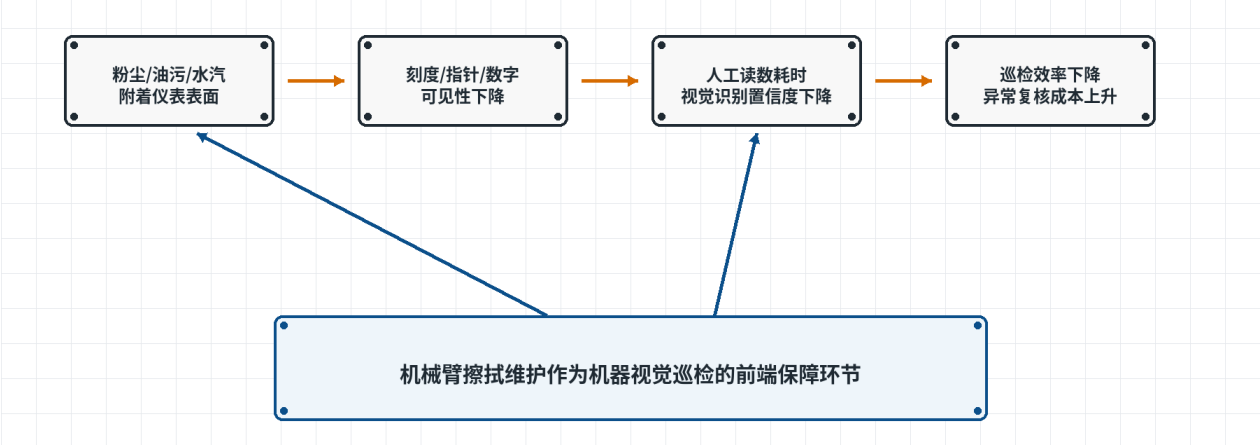


图 2-1 工厂仪表污染与巡检风险链路图

图 2-1 表明，仪表污染会首先影响人工观察和机器视觉输入，进而影响读数可靠性与维护效率。该图支撑了本项目的立意：擦拭系统应被视为智能巡检链路中的前端保障模块。

表 2-1 工业仪表维护方式比较

维护方式	优势	局限	适用场景
人工擦拭	灵活、可临时处理复杂情况	重复性劳动强，维护频次受人员安排影响	少量点位或临时巡检
固定轨迹机械臂	结构清晰，控制过程可解释	仪表位置和工具偏差变化时需重新调参	标准化工位
本项目方案	利用示教数据学习动作过程，具备一定工况适应能力	需要采集数据并进行模型训练和实机调试	固定或半固定工业巡检点位

为了对比人工维护和机械臂辅助维护的差异，图 2-2 根据巡检作业流程拆解绘制。该图用于说明本项目并不是要完全替代人工维护，而是把机械臂作为固定点位、重复性擦拭任务的辅助单元，与图像采集和读数判断形成联动。

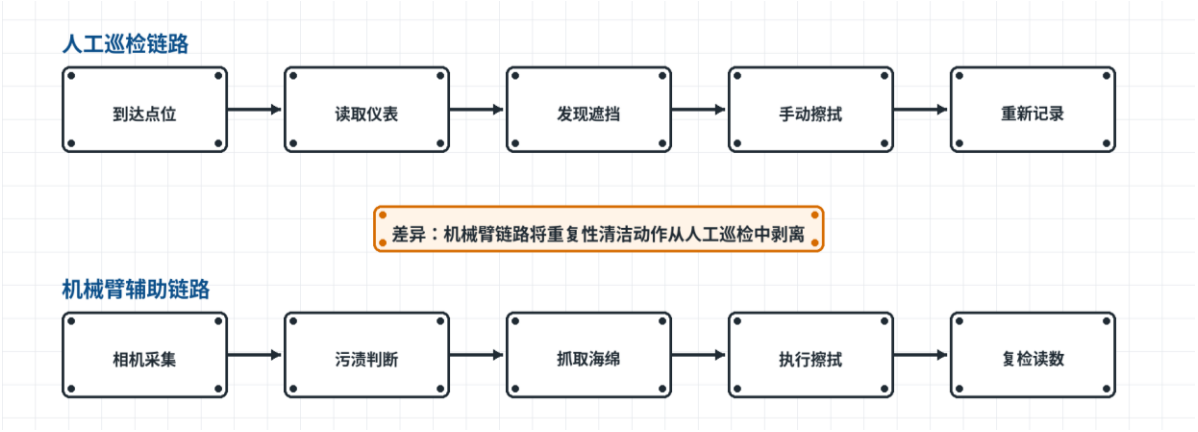


图 2-2 人工巡检与机械臂辅助维护对比图

从图 2-2 可以看出，人工流程强调现场发现和手动处置，而机械臂辅助流程强调感知触发、自动执行和复检闭环。该对比说明机械臂方案更适合高频、重复、固定点位的维护任务。

团队在实验平台上对仪表污染前后状态进行了现场拍摄，并将同一类仪表在擦拭前后的视觉效果并列整理为图 2-3。

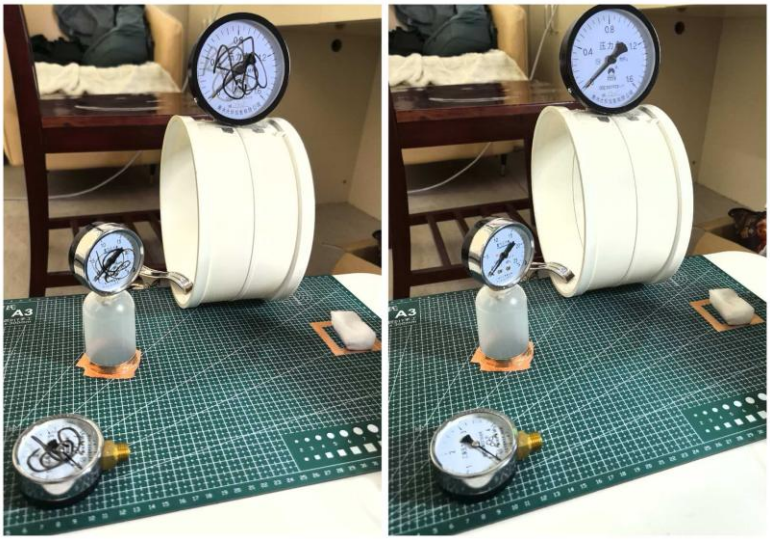


图 2-3 仪表擦拭前后对比图

图 2-3 显示，擦拭后仪表刻度和指针区域更加清晰，图像读数条件明显改善。这说明本项目的擦拭动作能够直接服务于人工巡检和机器视觉读数，而不是单纯追求表面清洁。这直观展示了污渍遮挡对读数区域和图像清晰度的影响，同时为后续污渍状态判断样本的人工标记提供依据。

2.2 国内外研究现状

在文献综述阶段，团队围绕“机器人擦拭、视觉伺服、模仿学习、ACT、工业巡检、机械臂清洁”等主题词，在知网、Google Scholar 和 IEEE Xplore 等平台进行检索，

并将论文题名、关键词和摘要中出现频率较高的词汇整理为主题词云。图 2-4 使用 Python 根据词频权重绘制，用于概括当前相关研究的主要关注方向。

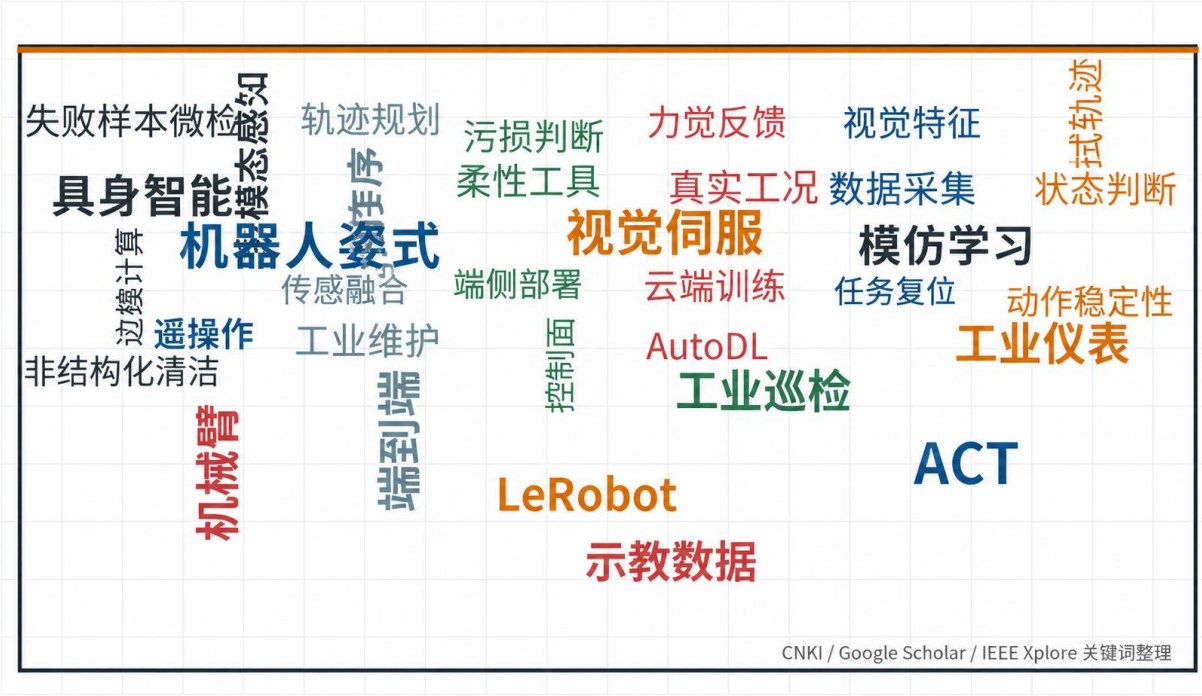


图 2-4 文献主题词云图

图 2-4 中“视觉伺服”“模仿学习”“机器人擦拭”“ACT”“工业巡检”等词出现较为突出，说明相关研究主要集中在视觉控制、机器人操作和学习策略方向。本项目的定位正是将这些方向组合到工业仪表维护场景中。

深度视觉感知方面，ResNet 通过残差学习缓解深层神经网络训练困难，为视觉特征提取提供了重要基础[1]。机器人擦拭方向中，Dometios 等提出基于视觉的运动基元在线自适应方法，体现了传统擦拭任务中“视觉建模—运动基元—控制执行”的路线[2]。运动基元方法本身也是机器人示教学习和轨迹复现中的重要技术路线，Saveriano 等对动态运动基元在机器人中的应用进行了综述，指出该类方法适合表达结构较明确的运动技能，但在复杂场景迁移中仍需要合理的动作建模和参数调整[7]。视觉伺服方向中，Liu 等通过自适应图像特征预测改善图像采集与计算延迟对控制稳定性的影响[3]。

在机器人学习方向，Zhao 等提出的 ACT 方法通过动作分块学习连续操作序列，适合低成本硬件上的遥操作模仿学习[5]；Diffusion Policy 则从扩散模型角度研究视觉运动策略学习[6]。与上述研究相比，本项目的特点不是单独提出新的基础模型，而是将自建 LeRobot 环境、ACT 动作学习和工业仪表擦拭维护场景结合起来，形成可实机验证的系统闭环。

第三章 项目研究内容与技术路线

3.1 系统硬件与 LeRobot 运行环境

只用实物照片难以看清主从机械臂、舵机总线、双相机和上位机之间的数据流与控制流，为展示各硬件模块之间的连接关系，根据团队硬件连接表、串口映射记录和相机布置方案绘制图 3-1。

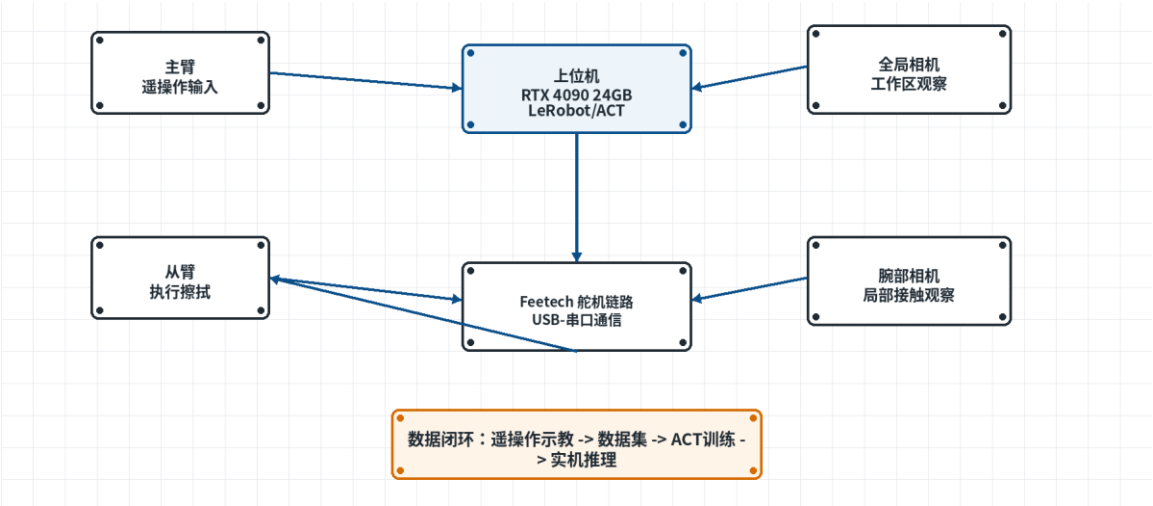


图 3-1 系统硬件拓扑图

图 3-1 展示了系统中主从机械臂、舵机通信、双相机和上位机之间的连接关系。该图反映出系统不是单一机械臂动作演示，而是由感知、通信、控制和执行模块共同构成的机器人系统。

项目的软件环境采用本地示教与本地部署、AutoDL 云端训练相结合的方式搭建。具体的训练与运行环境配置如表 3-1 所示。

表 3-1 训练与运行环境配置

类别	配置内容	作用
计算平台	AutoDL 平台 RTX 4090 24GB 云端训练实例；本地计算机用于采集和部署	完成模型云端训练、权重下载与本地推理验证
软件环境	Conda + Python + PyTorch + LeRobot	完成采集、训练、推理与机械臂控制
机械臂通信	Feetech 舵机总线与串口映射	实现主从机械臂控制
视觉系统	全局相机与腕部相机	获取整体场景和末端局部接触状态
任务工具	海绵、仪表盘、沙盘与厂房点位	构成仪表擦拭验证环境

本地计算机负责 Conda 虚拟环境、LeRobot 项目代码、串口通信依赖、双相机采集和推理部署；训练阶段将整理后的示教数据上传至 AutoDL 平台，租用 RTX 4090 24GB 实例完成模型训练，再下载训练权重回到本地机械臂平台验证。图 3-2 根据团队

环境配置记录绘制，目的是把“本地采集—云端训练—权重回传—本地执行”的工程闭环展示清楚。



图 3-2 团队自建 LeRobot 运行环境栈

图 3-2 展示了项目采用的本地采集与部署、AutoDL 云端训练的工程模式。该结构既降低了本地训练硬件压力，又保证训练后的权重能够回到真实机械臂平台完成验证。

3.2 多工况示教数据采集

图 3-3 根据团队采集计划表绘制，展示项目在目标位置、污渍状态、工具夹持、光照扰动和真实厂房背景等维度的覆盖情况。

	全局视角	腕部视角	关节状态	夹爪动作	任务结果
标准擦拭	✓	✓	✓	✓	✓
仪表位置偏移	✓	✓	✓	✓	✓
仪表角度/尺寸变化	✓	✓	✓	✓	✓
明显污渍	✓	✓	✓	✓	✓
局部污渍	✓	✓	✓	✓	✓
无明显污渍	✓	✓	✓	✓	✓
海绵抓取偏差	✓	✓	✓	✓	✓
失败样本补录	✓	✓	✓	✓	✓

图 3-3 多工况示教采集矩阵

图 3-3 说明数据采集覆盖了位置、污渍、工具、光照和真实场景等多个维度。该矩阵反映出项目在采集阶段有意识地扩展工况，而不是只录制标准动作。

团队最终整理了 201 个 episode。图 3-4 由 episode 文件夹统计表导出后使用 Python 绘制。

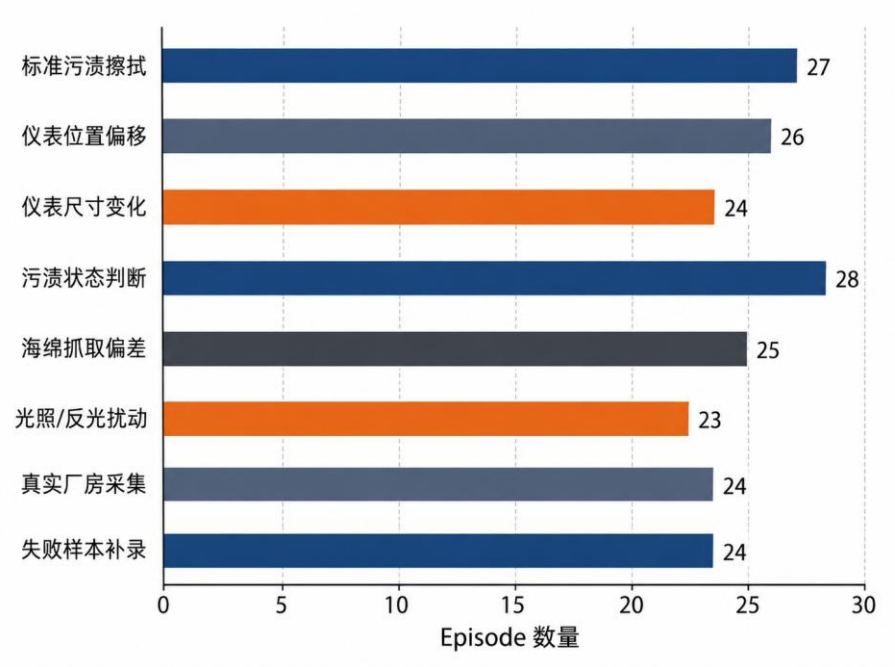


图 3-4 数据集工况构成统计图

图 3-4 显示各类工况 episode 数量相对均衡，主要类别均达到二十余集。该结果说明数据集能够为模型学习不同视觉状态和动作状态提供基本支撑。

表 3-2 进一步列出各工况数量和具体的采集目的。

表 3-2 示教数据集构成

工况类型	Episode 数量	采集目的
标准污渍擦拭	27	学习完整擦拭任务基准动作
仪表位置偏移	26	增强目标位置变化适应能力
仪表尺寸变化	24	覆盖目标尺度差异
污渍状态判断	28	学习不同污渍状态下的动作差异
海绵抓取偏差	25	提升工具夹持偏差容错能力
光照/反光扰动	23	提升视觉输入稳定性
真实厂房采集	24	补充实际环境图像和背景变化
失败样本补录	24	针对实机失败状态进行微调
合计	201	构成训练与验证数据基础

数据由实际机械臂平台、相机视角和 LeRobot 采集界面共同产生。主从遥操作、双相机安装和多工况采集过程均由团队现场拍摄记录，如图 3-5 至图 3-7 所示。



图 3-5 主从机械臂遥操作图

图 3-5 展示了操作者通过主臂控制从臂完成示教的过程。该图说明示教数据来源于人工实际操作，模型训练目标是复现和泛化这种专家动作序列。



图 3-6 双相机安装位置图

图 3-6 显示了全局相机和腕部相机的安装方式。全局相机用于观察整体位置关系，腕部相机用于补充末端附近的局部接触信息，两者共同增强视觉观测能力。

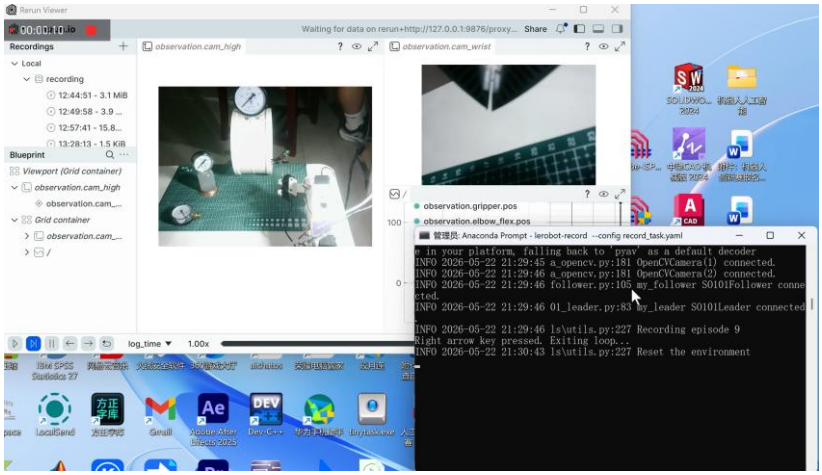


图 3-7 多工况数据采集样例图

图 3-7 呈现了 LeRobot 采集界面、相机画面和终端日志等运行状态。该图说明团队已完成从画面采集到 episode 保存的实际数据录制流程。

3.3 ACT 端到端动作学习方法

在完成硬件环境搭建和多工况示教数据采集后，项目需要进一步建立从视觉观测、机械臂状态到连续动作输出的策略模型。本节围绕 ACT 端到端动作学习方法，说明模型输入、特征编码、动作块输出、云端训练和本地部署之间的关系。

为进一步说明本项目中“图像输入如何转化为机械臂动作输出”，我们根据实际系统的数据流、模型结构和训练部署流程绘制了基于 ACT 的多模态动作学习与训练部署框图，如图 3-8 所示。该图将全局相机图像、腕部相机图像、关节状态、夹爪状态、特征编码、模态融合、ACT 动作分块网络、动作块输出、本地执行以及 AutoDL 云端训练闭环统一呈现。

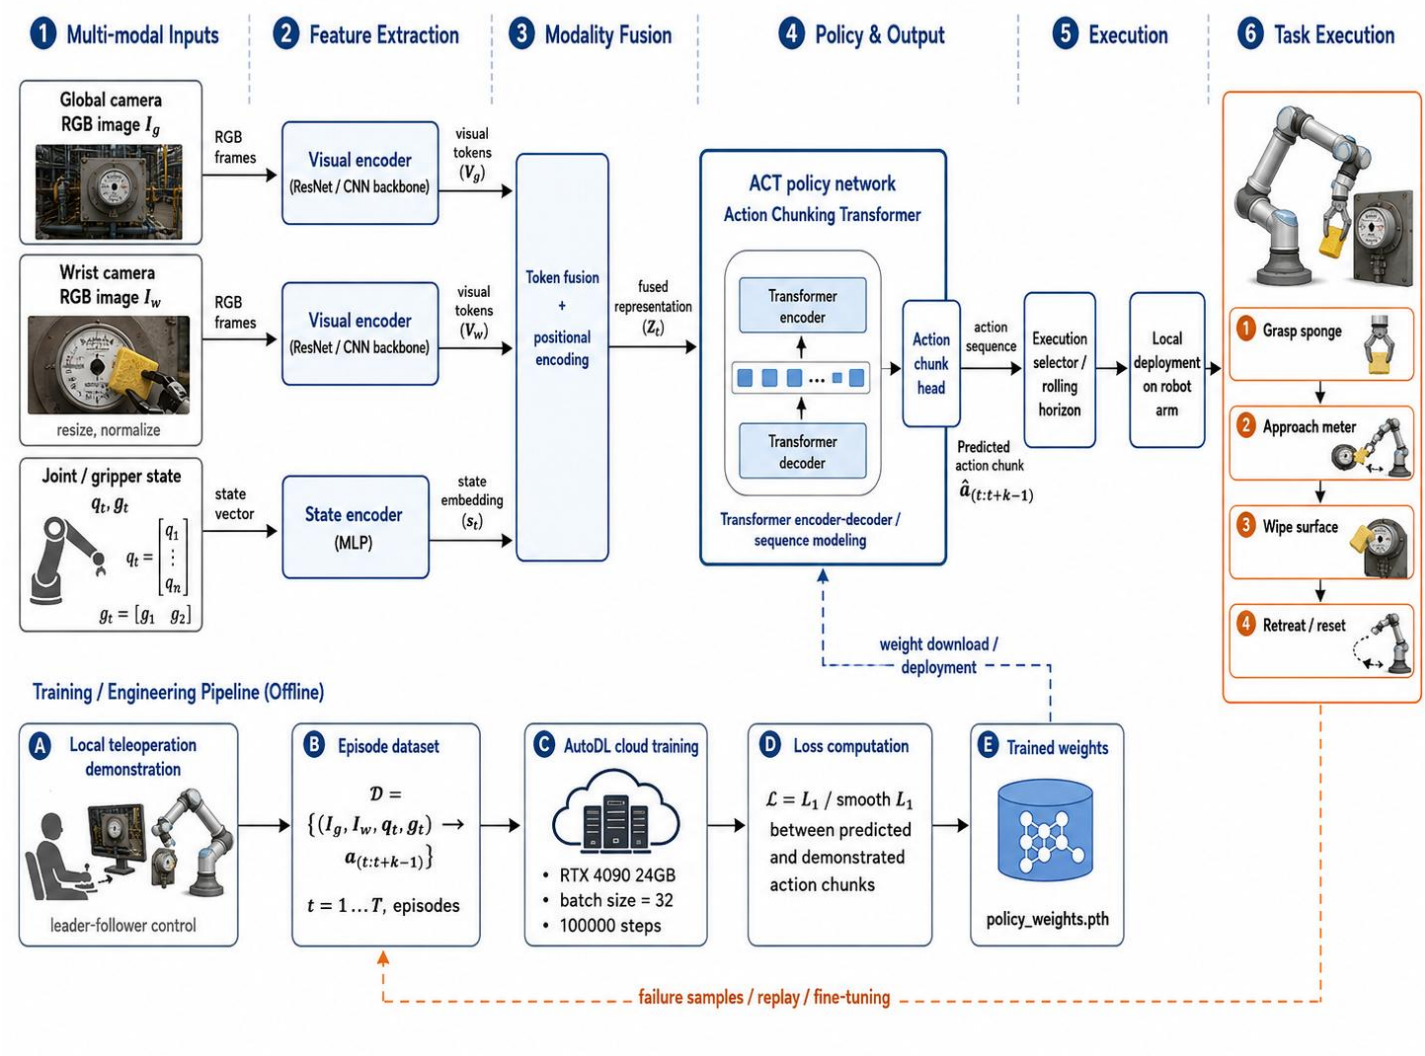


图 3-8 基于 ACT 的多模态动作学习与训练部署框图

图 3-8 上半部分展示了系统在线推理时的主数据流。全局相机输入 I_g 用于提供仪表、机械臂和工作空间的整体位置关系，腕部相机输入 I_w 用于补充海绵与仪表表面的

局部接触信息，关节状态 q_t 和夹爪状态 g_t 则提供机械臂当前姿态和末端执行器状态。两路图像分别经过视觉编码器提取视觉 token，关节与夹爪状态经过 MLP 状态编码器得到状态嵌入，随后在模态融合模块中进行 token 融合和位置编码，形成统一的状态表示。

在策略输出阶段，ACT policy network 不直接输出单步动作，而是通过 Action Chunking Transformer 预测未来一段连续动作块 $\hat{a}_{t:t+k-1}$。该动作块经过滚动时域执行机制下发到本地机械臂控制端，使系统能够连续完成海绵抓取、接近仪表、擦拭表面和撤离复位等动作。与单步动作回归相比，动作分块方式更适合擦拭这类具有连续阶段和长程依赖的任务，有助于降低逐步执行中的误差积累。

图 3-8 下半部分展示了系统离线训练和工程闭环。团队首先通过本地主从遥操作采集 episode 数据集，数据内容包括全局图像、腕部图像、关节状态、夹爪状态及对应的示教动作块；随后将数据上传至 AutoDL 云端训练环境，利用 RTX 4090 24GB 实例完成模型训练，并通过 L_1 或 smooth L_1 损失约束预测动作块与示教动作块之间的差异。训练完成后的权重下载回本地平台部署验证，实机运行中产生的失败样本再进入回放、补录和微调流程，从而形成“本地示教—云端训练—本地部署—失败样本再训练”的迭代闭环。

在明确网络输入、动作块输出和训练部署关系后，为交代模型训练的资源条件和可复现实验参数，并与“本地示教—云端训练—本地部署”的工程模式对应，绘制训练资源与关键参数如图 3-9 和表 3-3 所示。

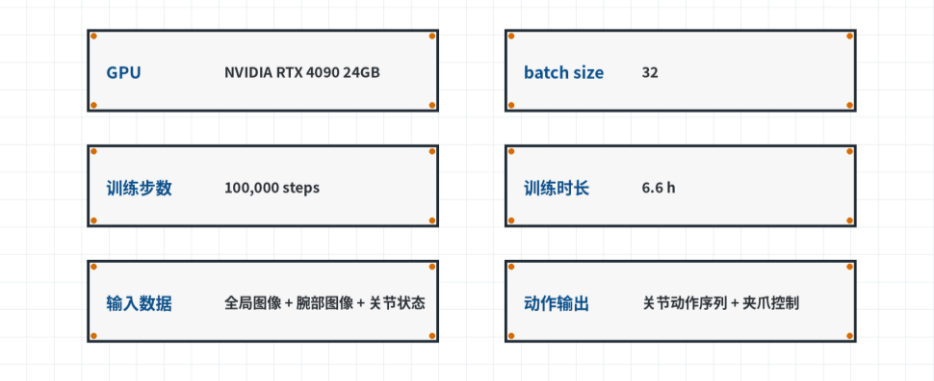


图 3-9 训练资源与参数记录面板

图 3-9 根据 AutoDL 训练台账和显卡运行记录绘制，记录了本项目采用的 RTX 4090 24GB 云端实例、batch size 32、100000 step 和约 6.6 h 训练时长等信息。

表 3-3 训练参数设置

参数	设置值	说明
GPU	AutoDL 租用 RTX 4090 24GB 实例	完成云端模型训练，训练后下载权重至本地部署
batch size	32	兼顾显存占用与训练稳定性
训练步数	100000 step	主模型训练步数
训练时长	约 6.6 h	单轮训练日志记录的平均耗时
输入模态	全局图像、腕部图像、关节状态、夹爪状态	构成多模态观测
输出内容	动作块、夹爪控制	用于连续擦拭执行

表 3-3 对图 3-9 中的关键训练条件作进一步整理，明确了 GPU、batch size、训练步数、训练时长、输入模态和输出内容等参数。其中，输入模态与图 3-8 中的网络输入保持一致，包含全局图像、腕部图像、关节状态和夹爪状态；输出内容则对应 ACT 模型预测的动作块和夹爪控制信号。

为比较不同输入模态和微调策略下的损失下降过程，同时观察模型在 100000 step 训练后是否进入相对稳定状态，绘制图 3-10，其由多组模型训练日志整理得到，使用 Python 将每 250 step 采样点进行滑动平均，并采用 2×3 小多图形式分别呈现。

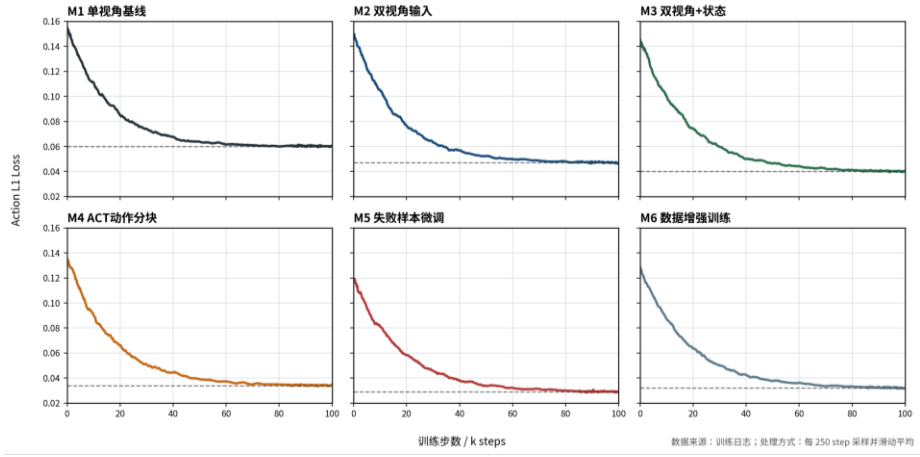


图 3-10 多组模型训练损失收敛曲线图

图 3-10 中各曲线前期下降较快、后期逐渐趋于平稳，说明模型经过足够步数训练后进入较稳定状态。不同配置之间的收敛速度和最终损失存在差异，其中双视角输入、关节状态融合和失败样本微调配置整体表现更稳定，为后续选择多模态输入和微调策略提供依据。

训练得到的策略网络最终需要在机械臂平台上展开为连续任务执行过程。为说明动作块输出在实机端如何对应具体任务阶段，团队依据实机控制流程绘制擦拭任务执行状态机，如图 3-11 所示；同时根据阶段性测试记录整理综合指标面板，如图 3-12 所示，用于展示系统能力分布和训练迭代效果。

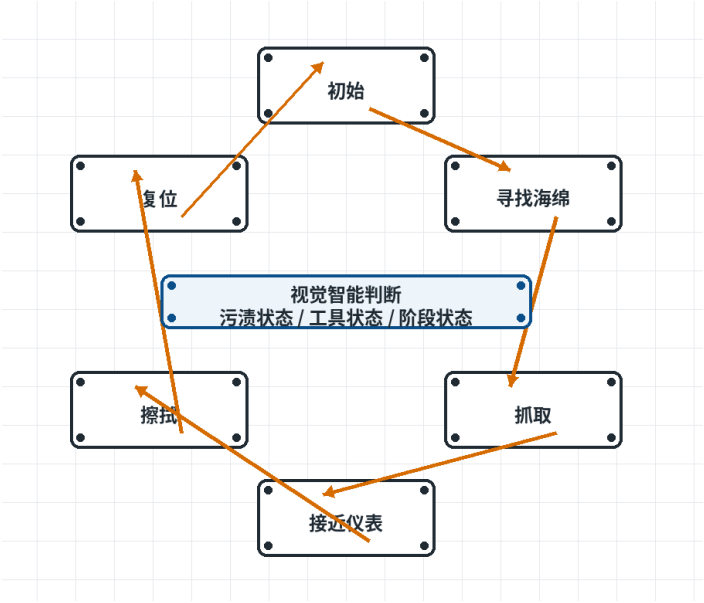


图 3-11 擦拭任务执行状态机图

图 3-11 展示了从初始、寻找海绵、抓取、接近仪表、擦拭到复位的阶段关系。该图说明 ACT 网络输出的连续动作块并不是孤立动作，而是在实机端对应到明确的任务阶段。后续若引入分层控制和异常检测机制，也可以围绕这些阶段展开。

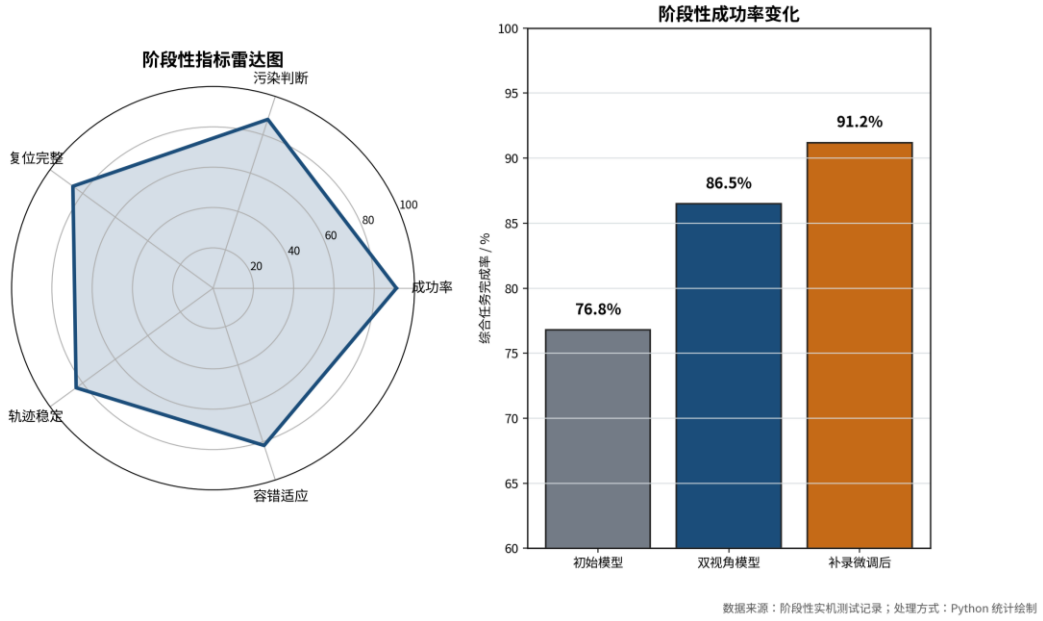


图 3-12 阶段性测试指标面板

图 3-12 将雷达指标和阶段成功率放在同一面板中，能够同时观察系统能力分布和训练迭代效果。图中微调后成功率提升，说明失败样本补录对典型工况具有改进作用，也与图 3-8 中“失败样本—回放—微调”的闭环逻辑相呼应。

第四章 模型训练、实机测试与结果分析

为保证后续实验结果具有可比性，本章首先明确实机测试协议与评价指标。测试在本地机械臂平台上完成，模型权重由 AutoDL 云端训练后下载至本地部署。测试数据主要来源于机械臂实机运行日志、相机采集画面、人工复核记录和失败样本统计表。测试内容覆盖标准擦拭、仪表位置偏移、污渍状态判断、海绵抓取偏差和光照扰动等典型工况，评价重点包括任务完成率、污渍判断准确率、末端定位偏差、阶段耗时和失败类型分布。具体测试协议如表 4-1 所示。

表 4-1 实机测试协议与评价指标

项目	设置
测试平台	本地机械臂实机平台
模型来源	AutoDL 平台 RTX 4090 24GB 实例训练后下载权重，本地部署验证
测试场景	桌面沙盘测试场景、真实厂房采集点位
测试工况	标准污渍擦拭、仪表位置偏移、污渍状态判断、海绵抓取偏差、光照/反光扰动
每类测试次数	每类 15–20 次，根据工况复杂度适当调整
成功判据	机械臂能够完成海绵抓取、接近仪表、执行擦拭并安全复位
主要评价指标	任务完成率、污渍判断准确率、末端定位偏差、阶段耗时、失败类型
数据来源	实机测试日志、相机图像记录、人工复核记录、失败样本统计表

表 4-1 明确了本章实验结果的统计口径。后续成功率对比、污渍状态判断混淆矩阵、视觉置信度与末端定位偏差散点图、阶段耗时箱线图等结果，均围绕上述测试协议展开。其中标准擦拭、位置偏移、污渍状态判断等主要工况测试次数不少于 20 次，真实厂房和强反光等补充工况根据现场条件完成 15 次以上验证。

该表将实验过程从单次演示转化为可复核的测试流程，使后续图表具有统一的评价基础。需要说明的是，表 4-1 中的测试记录来自训练完成后的实机部署验证过程，不直接等同于训练 episode 本身；测试时按照典型工况重新运行任务，并由运行日志、相机画面和人工复核共同确认结果。

4.1 消融测试与微调效果

基于表 4-1 所示的测试协议，团队进一步对不同模型配置进行了消融对比。对比内容包括单全局视角输入、双视角输入、双视角与关节状态融合、ACT 动作分块策略以及失败样本微调等设置。设置消融实验的目的，是判断系统性能提升主要来自视觉信息补充、状态信息融合、动作分块建模，还是来自后续失败样本补录与微调。各配置下的测试结果汇总如表 4-2 所示。

表 4-2 消融实验结果汇总

模型配置	主要输入或策略	任务完成率	主要现象
单全局视角模型	全局相机图像	76.8%	能完成基本接近动作，但末端接触阶段误差较多
双视角模型	全局图像 + 腕部图像	84.5%	接近仪表和局部擦拭过程更稳定
双视角 + 关节状态模型	全局图像 + 腕部图像 + 关节状态	88.1%	阶段切换更平滑，复位动作更稳定
ACT 动作分块模型	多模态输入 + 连续动作块输出	89.4%	长程动作连贯性提升，擦拭过程抖动减少
ACT + 失败样本微调	多模态输入 + 动作分块 + 失败样本补录	91.2%	对抓取偏差、污渍判断和擦拭偏移的适应性进一步改善

由表 4-2 可知，随着输入信息和训练策略逐步完善，模型任务完成率呈现持续提升趋势。单全局视角模型能够学习基本任务流程，但对末端局部接触状态感知不足；加入腕部视角后，模型能够更好观察海绵与仪表之间的相对位置；进一步融合关节状态后，动作阶段切换和复位稳定性有所改善。ACT 动作分块策略使模型能够一次预测未来一段动作序列，更适合“抓取—接近—擦拭—复位”这类连续任务。失败样本微调则主要改善了抓取偏差、污渍判断和擦拭偏移等薄弱环节。

在表 4-2 的基础上，图 4-1 进一步从典型工况角度展示微调前后任务完成率的变化。该图根据实机测试记录统计得到，用于观察失败样本补录对不同工况的改善效果。图 4-2 则依据文献综述中的技术路线整理出本项目与传统方法的差异，用于从方法定位层面说明本项目采用端到端动作学习路线的原因。

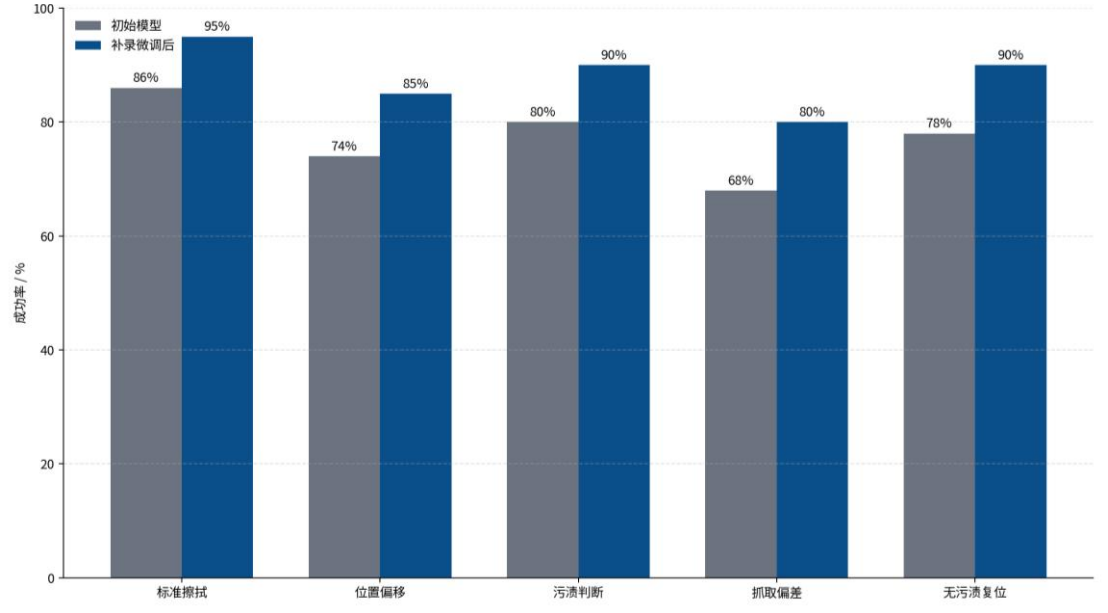


图 4-1 微调前后典型工况成功率对比

图 4-1 显示，微调后各典型工况成功率均有提升，尤其是在抓取偏差和污渍判断相关场景中提升较明显。该结果与表 4-2 中“ACT + 失败样本微调”配置的整体表现一致，说明失败样本补录能够针对模型薄弱环节产生实际作用。



图 4-2 与相关技术路线对比矩阵

图 4-2 从建模依赖、视觉输入、适应能力和部署复杂度等维度比较了不同技术路线。该图说明，本项目并非依赖固定轨迹或显式动力学模型完成擦拭，而是通过多工况示教数据和 ACT 动作分块策略学习连续动作过程，更适合处理仪表位置变化、海绵夹持偏差和污渍状态差异等实际工况。

在复杂机器人操作中，传统鲁棒控制常通过显式动力学建模、优化约束和误差补偿处理不确定性，例如 Liu 和 Billard 针对释放不确定性提出 Tube Acceleration 方法[4]。与此类方法相比，本项目面对的主要不确定性来自仪表位置变化、柔性海绵抓取偏差和污渍状态差异，因此更侧重通过示教数据覆盖、失败样本补录和端到端策略微调改善执行效果。

4.2 失败类型、污渍判断与定位偏差

为把“失败发生在哪里”和“数据采集如何应对工具偏差”联系起来，说明系统优化并不是只依赖单次成功演示，而是围绕典型失败状态进行补录和微调，根据失败样本记录表统计绘制图 4-3，根据训练时主动覆盖的海绵夹持偏差状态绘制图 4-4。

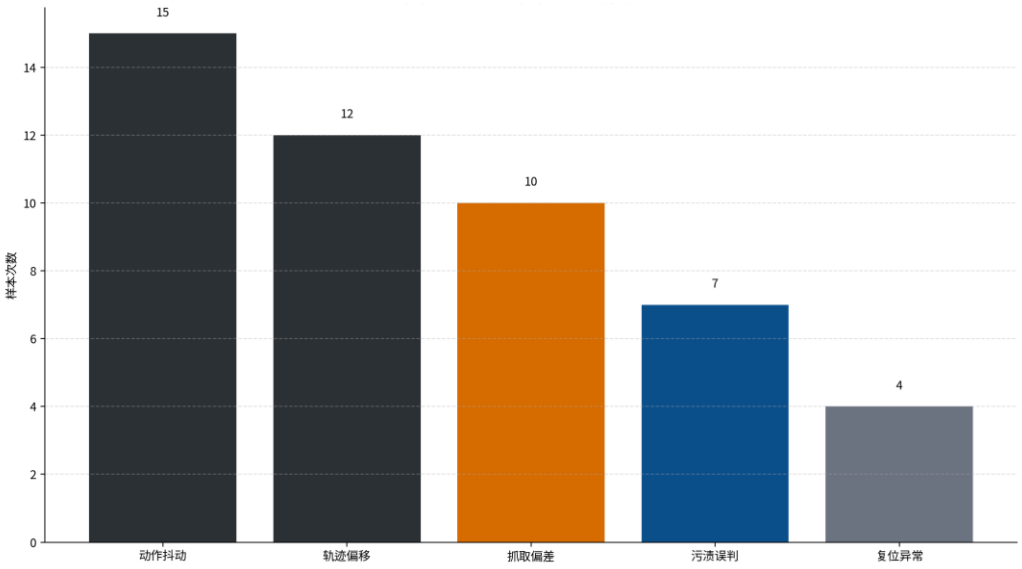


图 4-3 失败样本类型统计图

图 4-3 显示擦拭偏移、抓取不稳和污渍误判占比较高，说明前期系统主要问题集中在接触执行和视觉判断环节。这为后续补录样本和优化控制策略提供了方向。

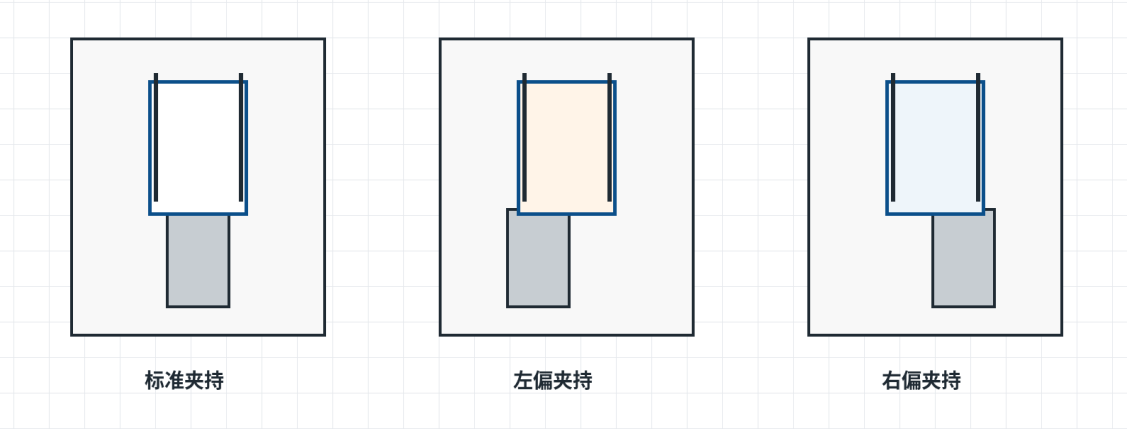


图 4-4 海绵抓取偏差容错示意图

图 4-4 展示了标准夹持、左偏夹持和右偏夹持三类状态。该图说明项目在训练时主动考虑柔性工具抓取误差，使模型具备一定工具姿态容错能力。

团队同时拍摄了实际海绵抓取偏差状态，如图 4-5 所示。该实拍图与图 4-4 的示意图对应，用于说明容错数据并非概念化设计，而是在真实夹爪和海绵工具状态下进行采集。

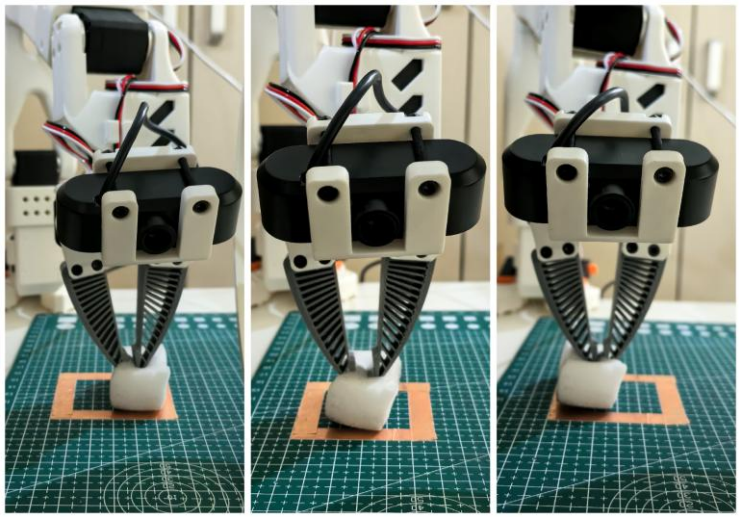


图 4-5 海绵抓取偏差实拍图

图 4-5 与图 4-4 相互印证，表明偏差样本在真实夹爪和海绵条件下采集。该图反映出实际执行中工具状态并不总是标准一致，因此容错训练具有必要性。

污渍状态判断混淆矩阵由人工标记类别和模型输出类别交叉统计得到，如图 4-6 所示。图 4-7 则来自实机测试日志，将视觉置信度与末端定位偏差对应绘制为散点图，用于观察视觉判断质量和执行精度之间的关系。

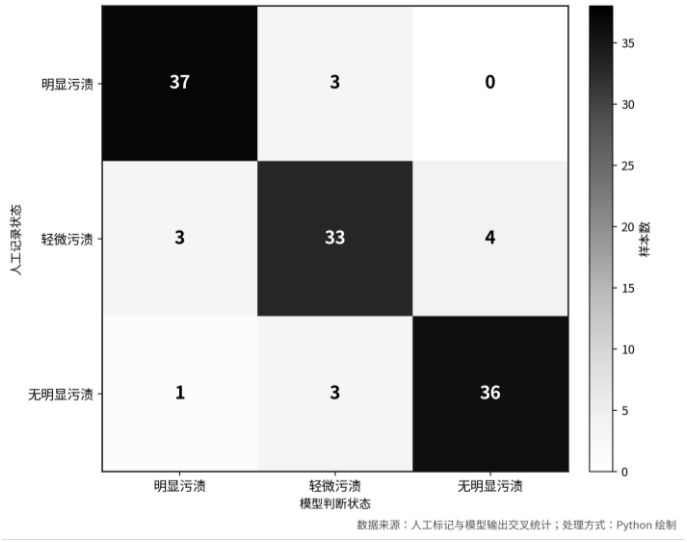


图 4-6 污渍状态判断混淆矩阵

图 4-6 显示主要类别集中在对角线上，说明模型对明显污渍、轻微污渍和无明显污渍具备一定区分能力。非对角项仍然存在，表明轻微污渍和边界状态是后续改进重点。

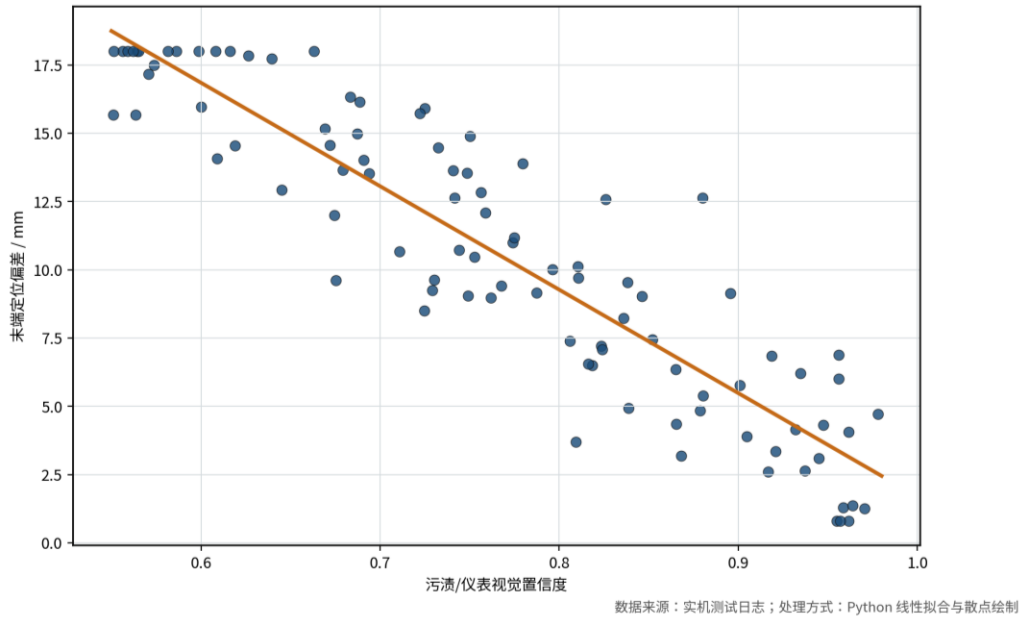


图 4-7 视觉置信度与末端定位偏差散点图

图 4-7 显示视觉置信度较高时末端定位偏差通常较小，说明视觉判断质量会影响后续执行精度。该结果提示后续应继续提升强反光和遮挡条件下的视觉稳定性。

4.3 阶段耗时与综合指标

单次任务耗时被划分为抓取工具、接近仪表、擦拭执行和离开复位四个阶段。图 4-8 根据任务运行日志绘制箱线图，图 4-9 根据测试记录和人工评分整理为雷达图。设置这两张图的意义，是分别从“时间分布”和“综合能力”两个角度评估系统表现。

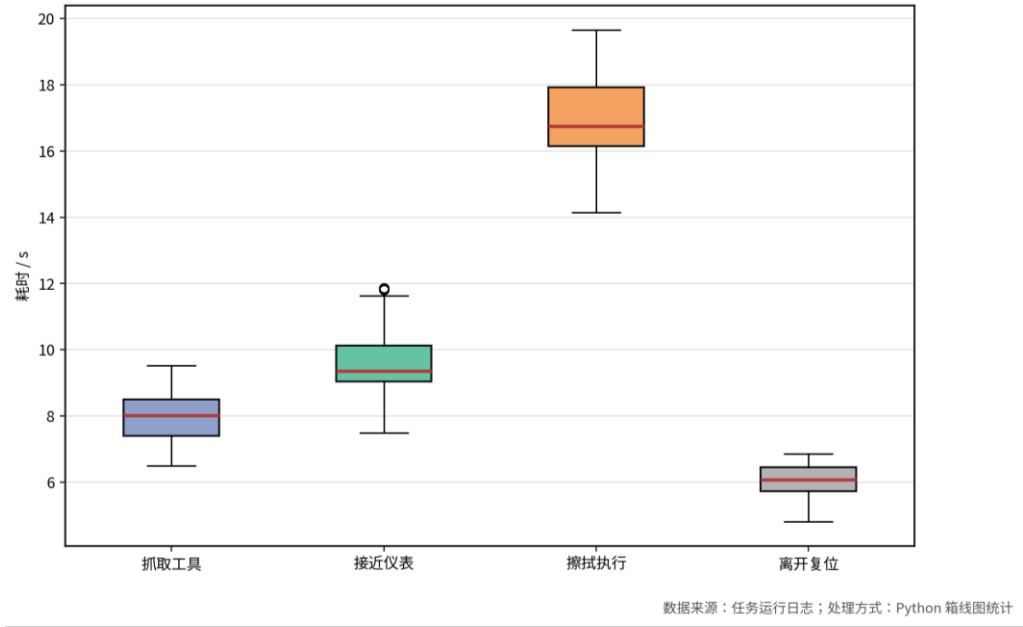


图 4-8 单次任务各阶段耗时分布

图 4-8 表明擦拭执行阶段耗时最长且波动较大，抓取和复位阶段相对稳定。该结果说明长程任务优化重点应放在接触擦拭过程的稳定性和路径一致性上。

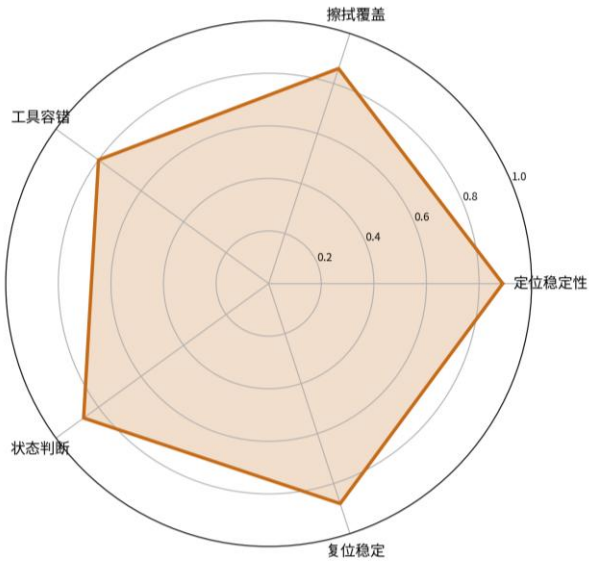


图 4-9 系统综合能力雷达图

图 4-9 显示系统在视觉感知、擦拭完成和部署便利性方面表现较好，而长程稳定性和场景扩展仍有提升空间。该图为第六章问题分析和改进方向提供了量化依据。

第五章 项目创新点、应用前景与社会价值

5.1 创新点分析

项目创新点主要体现在应用场景选择、系统闭环实现、多模态数据采集和失败工况微调等方面，见表 5-1。

表 5-1 项目创新点归纳

创新点	具体体现	意义
场景聚焦	面向工业仪表表面维护，而非通用抓取演示	任务有明确工业背景和展示价值
环境自建	团队自主搭建 LeRobot 运行环境并完成训练推理闭环	体现系统工程能力
多模态输入	融合全局视角、腕部视角、关节状态和夹爪状态，并通过 ACT 网络输出连续动作块	提高位置和接触状态感知能力
容错训练	覆盖海绵抓取偏差和失败样本补录	改善真实执行中的薄弱环节

为说明本项目不仅是实验台上的擦拭动作演示，还可以作为视觉巡检链路中的前端维护模块，与图像采集、读数识别和运维记录形成联动。根据工业巡检应用流程绘制图 5-1，根据项目应用设想绘制图 5-2。

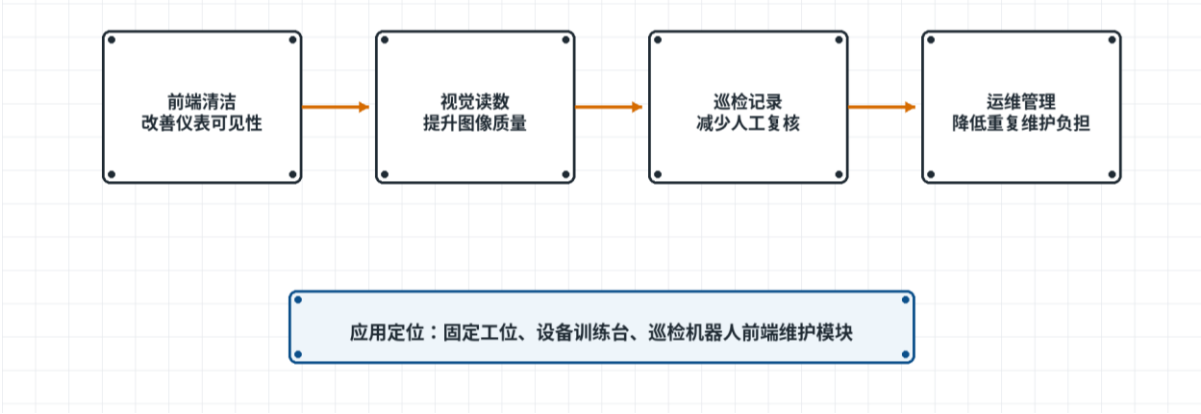


图 5-1 工业应用价值链图

图 5-1 说明机械臂擦拭可作为视觉巡检前端维护环节，改善图像质量后再进行读数识别和记录。该价值链体现了本项目从单一动作到工业流程嵌入的应用思路。

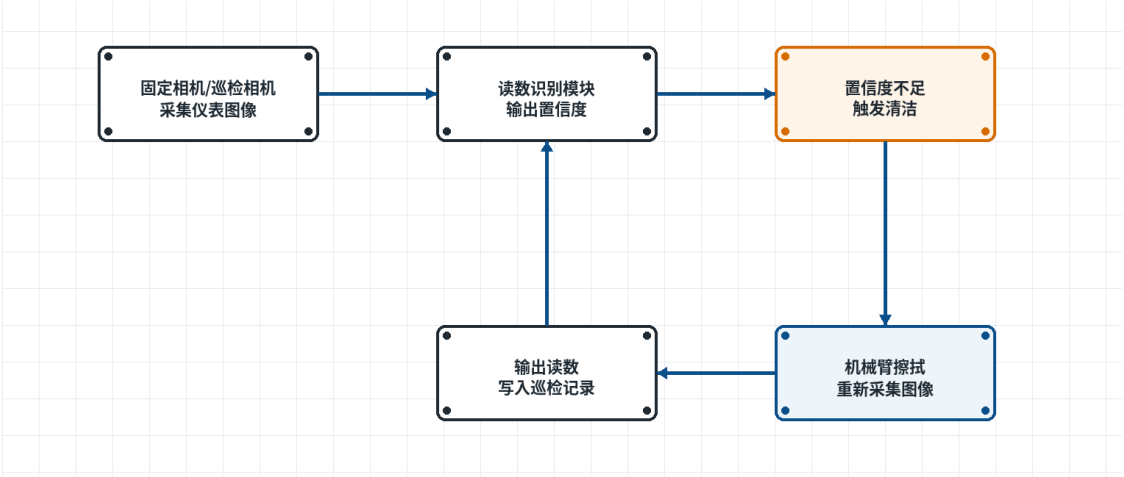


图 5-2 视觉巡检与机械臂维护联动架构图

图 5-2 表明，当视觉读数置信度不足时，系统可以触发机械臂擦拭，再重新采集图像并写入运维记录。该架构展示了后续与巡检平台集成的可行路径。

5.2 应用前景与社会价值

本项目可在固定仪表面板、设备训练台、低风险厂房巡检点位和实验室教学平台中进行小规模部署。图 5-3 根据应用场景拆解绘制，目的是展示系统从仪表擦拭向控制面板、传感器窗口和设备外壳等非结构化清洁任务扩展的可能边界。

	目标定位	污染判断	接触擦拭	复检记录
固定仪表盘	可扩展	可扩展	可扩展	可扩展
控制柜面板	可扩展	可扩展	可扩展	可扩展
设备观察窗	可扩展	可扩展	可扩展	可扩展
实验台面	可扩展	可扩展	可扩展	可扩展

图 5-3 场景扩展矩阵图

图 5-3 显示仪表擦拭、控制面板维护、设备外壳清洁和实验台面整理等任务具有一定共性。该图说明项目方法具备向低风险、固定点位非结构化清洁任务扩展的潜力。

项目已进行桌面沙盘和真实厂房采集测试，图 5-4 由团队现场拍摄，用于体现实验场景从可控沙盘向实际环境的过渡。设置该图的意义，是证明系统验证并未停留在单一实验桌面，而是开始接触真实厂房中的背景干扰、空间约束和仪表安装条件。



图 5-4 厂房测试场景图

图 5-4 展示了真实厂房中管道、仪表、背景设备和笔记本采集平台共存的状态。该图说明真实环境比实验沙盘更复杂，也解释了后续需要扩充真实场景数据的原因。

第六章 存在问题与后续改进方向

6.1 当前存在的问题

当前系统仍处于原型验证阶段，主要问题包括真实场景覆盖范围仍有限、接触力反馈不足、强反光条件下视觉稳定性需提升、长程任务状态切换仍可能受到前序误差影响等。图 6-1 根据团队复盘记录绘制鱼骨图，目的是把问题来源按照数据、感知、控制、接触和安全等方向进行归纳。

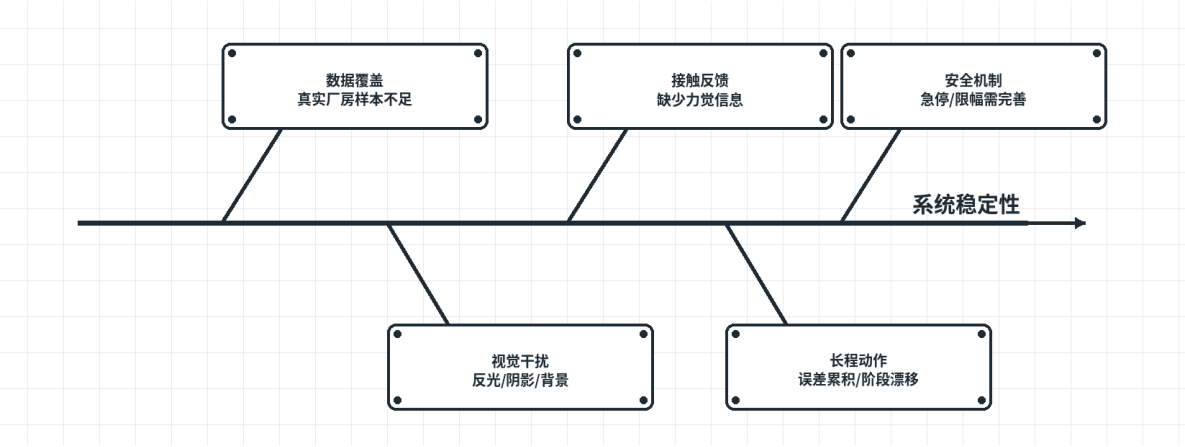


图 6-1 当前问题鱼骨分析图

图 6-1 将当前问题归纳为数据覆盖、感知稳定、接触反馈、长程控制和安全机制等方面。该图说明项目已经完成原型验证，但要进入更稳定应用仍需系统化改进。

表 6-1 主要问题与改进方向

问题	表现	改进方向
数据覆盖仍有限	真实厂房、复杂光照和更多仪表类型不足	扩充多场景长期数据集
接触反馈不足	擦拭压力主要依赖示教经验	加入力觉或关节电流反馈
长程稳定性需提升	抓取偏差会影响后续接触阶段	引入分层控制和阶段检测
安全机制需完善	异常动作和目标丢失需要保护	增加动作限幅、急停和异常检测

表 6-1 进一步将问题、表现和改进方向对应起来。可以看出，当前系统的主要不足并不集中在单一模块，而是分布在数据覆盖、接触感知、长程控制和安全保护等多个层面。因此，后续优化需要同时从数据、模型、硬件反馈和控制策略四个方向推进。

6.2 后续改进方向

图 6-2 根据后续研发计划绘制工程化改进路线，图 6-3 根据下一阶段系统结构设想绘制。两张图分别用于说明时间维度上的改进安排，以及加入力觉或电流反馈后系统信息流如何变化。

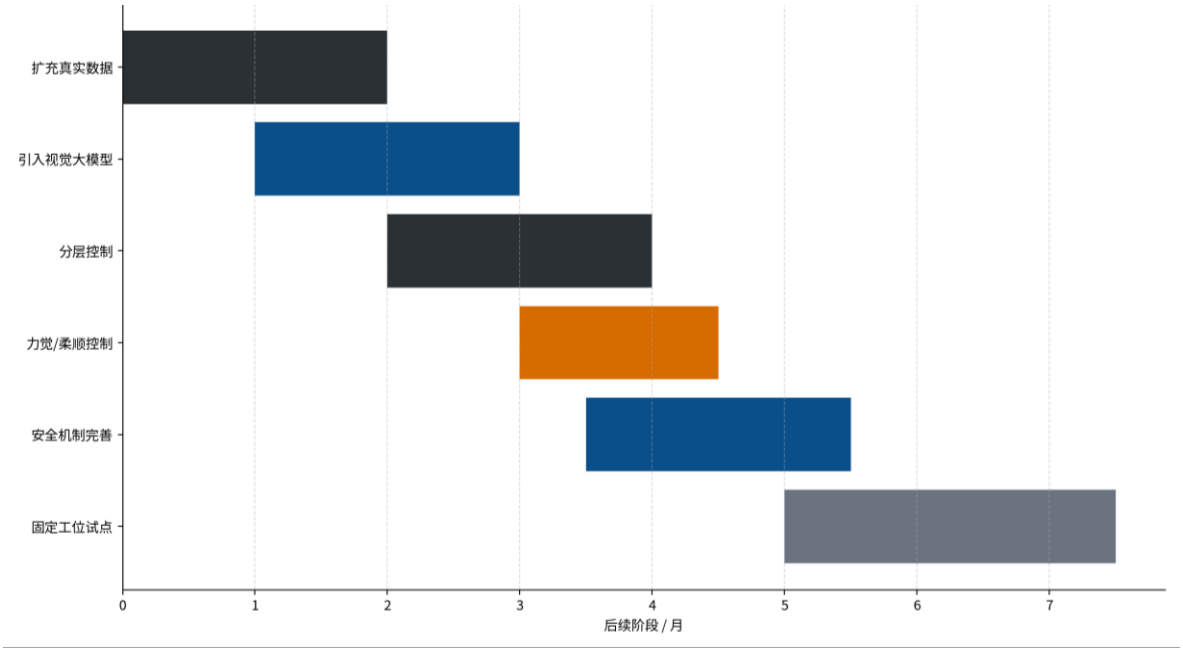


图 6-2 后续工程化改进路线图

图 6-2 给出了从真实数据扩充到长期运行优化的改进顺序。该路线表明后续工作应先补足数据与感知短板，再逐步推进固定工位试点和巡检平台联动。

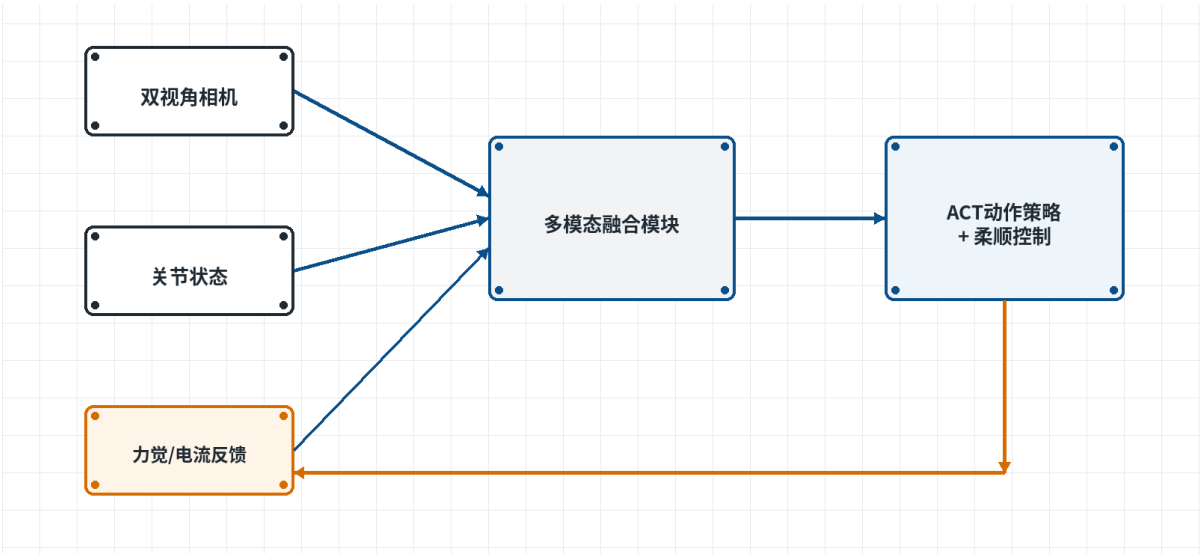


图 6-3 加入力觉反馈后的系统架构图

图 6-3 展示了加入力觉或电流反馈后，系统可在视觉和关节状态之外获得接触信息。该结构有助于改善擦拭压力控制和接触稳定性，是后续工程化的重要方向。

综合来看，后续工作可从三个方面展开。第一，继续扩充真实厂房、复杂光照、不同仪表类型和多种污染状态下的数据，使模型具备更充分的工况覆盖能力。第二，在现有视觉输入和关节状态基础上，引入力觉传感器或关节电流反馈，使系统能够感知擦拭接触状态，降低柔性工具接触不稳定带来的影响。第三，建立分层控制和异常

检测机制，将“寻找工具—抓取—接近仪表—擦拭—复位”等阶段显式纳入任务监控过程，提升长程任务执行的安全性和稳定性。

6.3 项目总结

总体来看，本项目初步验证了基于示教数据和端到端动作学习的机械臂系统在工业仪表维护任务中的可行性，为具身智能技术进入工业基础运维场景提供了一个可展示、可迭代的实践样例。后续仍需围绕真实场景数据扩充、力觉反馈引入、分层控制、异常检测和固定工位长期测试继续完善，使系统从原型验证逐步走向更稳定的工程应用。

参考文献

[1] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778. DOI: 10.1109/CVPR.2016.90.

[2] Dometios A C, Zhou Y, Papageorgiou X S, Tzafestas C, Asfour T. Vision-Based Online Adaptation of Motion Primitives to Dynamic Surfaces: Application to an Interactive Robotic Wiping Task[J]. IEEE Robotics and Automation Letters, 2018, 3(3): 1410-1417. DOI: 10.1109/LRA.2018.2800031.

[3] Liu C, Ye C, Shi H, Lin W. Discrete-Time Visual Servoing Control with Adaptive Image Feature Prediction Based on Manipulator Dynamics[J]. Sensors, 2024, 24(14): 4626. DOI: 10.3390/s24144626.

[4] Liu Y, Billard A. Tube Acceleration: Robust Dexterous Throwing Against Release Uncertainty[J]. IEEE Transactions on Robotics, 2024. DOI: 10.1109/TRO.2024.3386391.

[5] Zhao T Z, Kumar V, Levine S, Finn C. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware[C]//Robotics: Science and Systems. 2023. DOI: 10.15607/RSS.2023.XIX.016.

[6] Chi C, Xu Z, Feng S, Cousineau E, Du Y, Burchfiel B, Tedrake R, Song S. Visuomotor Policy Learning via Action Diffusion[J]. The International Journal of Robotics Research, 2025. DOI: 10.1177/02783649241273668.

[7] Saveriano M, Abu-Dakka F J, Kramberger A, Peternel L. Dynamic Movement Primitives in Robotics: A Tutorial Survey[J]. The International Journal of Robotics Research, 2023, 42(13): 1133-1184. DOI: 10.1177/02783649231201196.